

NAP 的具体实现过程

NAP(Nuisance Attribute Projection) 可以看成是一种在话者特征超矢量空间中通过 KPCA 方法去除信道信息的算法。其输入的超矢量可以任意，只要是能够表征任务所需的特征向量都行，如通用线性区分核函数 GLDS，GMM 超向量等。下面简单描述其实现过程：

NAP 的目的是期望在 SVM 超向量空间去寻找受信道干扰最小的、最能表征说话人身份特性的一个高维空间（我们也称该高维空间为说话人空间），通过将原始特征超向量向该说话人空间进行投影从而去除信道信息，降低或消除训练数据和测试数据之间的不匹配程度。因此，NAP 的关键问题是寻找一个与信道无关的只包含说话人信息的空间 P ，然后将所有高维超向量向空间 P 进行特征映射，去除信道的干扰。假设矩阵 \mathbf{P} 的零空间被向量 ω 所支撑，则 \mathbf{P} 有如下形式：

$$\mathbf{P} = \mathbf{I} - \omega\omega^t, \text{ with } \|\omega\| = 1 \quad (3.12)$$

则超向量投影后的新特征向量为 $\hat{\phi}(x) = \mathbf{P}\phi(x)$ ，问题转化为求出 ω 。我们定义 SVM 在训练集上内积核矩阵 \mathbf{K} 中 $\mathbf{K}_{ij} = \phi(x_i) \cdot \phi(x_j)$ 。所有 $\phi(x)$ 超向量排列起

NAP是为svm专门定制的信道补偿算法，应用场合是在非常高维的场合，NAP将本来非常分散、混淆的数据分布特性聚集得更紧凑了（同类样本那些离类中心很远的点可能正是由于信道的影响而偏离了类别本身的主方向），即映射的特征分布更能反映一类数据的主要特性了，也可以说是NAP投影后的数据特征类内方差变小了，从而更加利于用来分类和识别。

NAP中最后一步采用PCA分解时的矩阵反映的不只是方差而已，而且加入了不同信道或者话者之间的区分性信息。NAP是把数据集中主成分表示成各个变量的线性组合，NAP矩阵分解时重点是找到各向量之间的总体方差的一个解释，

LDA的输入数据是带标签的，通常来说作为作为一个独立的算法存在

类内协方差规整是一种应用于SVM核空间的特征规整方法。WCCN最初由Andrew O. Hatch和S. Andreas在2006年研究SVM应用于说话人识别的核方法选择时发现的，

NAP空间训练时需要知道每句话的信道类别信息，而WCCN是一种无监督的训练，不需要知道每句话的信道类别标号等信息，只需要知道是否是属于同一位说话人。

感兴趣的读者请见参考文献^[80]中第四节的定理1和定理2。从推导过程中我们发现，WCCN充分利用了训练数据中说话人类别标号信息去确定能够最大化与任务相关信息的特征空间中的正交方向。然而，跟以前的信道属性干扰投影算法NAP不同的是，它还充分挖掘了每个正交方向在特征空间位置上影响的权重信息来共同达到最小化错误率上界的目标^[78]。下面简单介绍一下WCCN的实现方法：

WCCN跟NAP的比较：我们发现WCCN跟NAP两者之间既有相似的地方也同时存在原理及物理意义上的本质性区别，主要体现在以下几个方面：

1. WCCN和NAP两者的目标都是希望能在特征空间中最大化与任务相关的信息，最小化任务之外的噪声或者干扰点的影响。寻找在高维超向量特征表面下隐含的最本质的元素或特征分布的方向。
2. NAP空间训练时需要知道每句话的信道类别信息，而WCCN是一种无监督的训练，不需要知道每句话的信道类别标号等信息，只需要知道是否是属于同一位说话人。
3. NAP没有根据每个类别训练数据量的多少来对空间训练进行调节，而WCCN在训练过程中则加入了类别先验概率信息来平衡各类别数据量对整个协方差矩阵的贡献。